运行与验证证据

> 四部分：AGH 执行记录说明、探针清单（可复现命令）、CASP14 基准实测分数、正常/边界/异常三类测试样例。

一、AGH 执行记录

- **会话级记录**：平台每个任务对应一个 AGH agent 会话（`sdk.session.new({ cwd, preset: 'standard' })` 创建，`orchestrator.ts:381`）。AGH 将会话事件（提示词、工具开启/结果、异常）写入会话日志；断线重连走 `sdk.session.load` 回放（`orchestrator.ts:538`），归档的任务元数据中保存了 `sessionId` 可回溯对应会话。
- **工具调用过程**：agent 的每次工具调用（`predict_structure` / `predict_complex` / `batch_predict` / `uniprot_search` / `compare_with_alphafold`）在会话事件流中留有完整的开启与结果事件；前端进度页即对该事件流做账本归约实时呈现（工具开启 → 阶段点亮）。
- **平台侧记录**：VPS 上 daemon 运行日志 + Caddy 访问日志 + 平台归档（`archive/` 目录，含 report.json / model.pdb / pae.json / 预生成缩略图），三者时间戳可交叉印证一次真实预测的发生。
- **导出方式（已实际交付）**：三个代表性会话已由 **AGH CLI 原生** `agnes export` 从 daemon 会话账本直接导出，文件在 `运行证据/` 目录（HTML 轨迹视图 + JSONL 原始事件流各一份，导出命令与事件类型速查见该目录 `README.md`）：

导出文件	平台任务	工具调用链
`AGH执行记录-01-P69905单体`	taskId `tmv8foc7xfimt`，血红蛋白 α（141 aa），平均 pLDDT 96.7	`uniprot_fetch` → `predict_structure` → `analyze_confidence`
`AGH执行记录-02-复合物`	taskId `tmv8cu0wqq606`，双链 + 配体 SMILES，平均 pLDDT 77.9	`predict_complex`（Boltz-2 多链，含 PAE / ipTM）
`AGH执行记录-03-CASP14-T1025`	taskId `tmv84cr0xxr66`，CASP14 靶标 T1025，平均 pLDDT 94.6（实测 Cα-lDDT 0.952 / Cα-RMSD 0.65 Å）	`predict_structure` → `analyze_confidence`

导出为 AGH 原生命令产出（非人工整理），默认脱敏（密钥、绝对路径、个人标识），HTML 页眉标注 `redacted`；原始事件流含 `session/start`、`user/message`、`step/start`、`request/sent`、`tool/call`、`tool/result`、`cost/ledger`、`verifier/signal`、`turn/end` 等完整类型，可逐条复核。

二、探针清单（全部可复现）

单元/集成探针位于 `examples/packages/dev-tests/`，本地执行：

探针	覆盖	断言数
`archive-put.mts`	归档装配、回填（meanPlddt/verdict）、路径穿越防护、批量 jobPdbs、超预算降级、绝对路径归一	13
`boltz-flow-unit.mts`	预测流全生命周期：wait=false 提交、鉴权回退、指标缩放、失败任务上抛、复合物守卫、PAE 拾取、陈旧 npz 回退、超时恢复、本地模式	42
`pp-lddt-unit.mts`	Cα-lDDT 数学：NW 对齐、全等=1、随机≈0、Horn 叠合 RMSD、退化 Jacobi 幂迭代情形（合成结构，无 daemon/网络）	22

探针	覆盖	断言数
`pp-bench-page.mjs`	基准页渲染契约（拦截 `api/bench` 注入夹具，锁定打分单元格 / 校准直方图 / nav 入口）	—
真基准页只读核验	登录后直读公网 `/platform/api/bench` 与 `#/bench`：Cα-lDDT / Cα-RMSD 列、平均 pLDDT 评分与 pLDDT 校准直方图均与本文档一致	—
`pp-platform-live.mjs`	公网端到端：登录→提交→阶段进度→结果页→归档重建	—
`pp-archive-roundtrip.mjs`	归档往返：写入→换会话读取→结果页重建	—
`pp-batch-smoke.mjs` / `pp-compare-smoke.mjs`	批量任务 / AlphaFold 对比链路冒烟	—
`pp-lookup-unit.mts`	共享检索模块（`uniprot.mjs`）：URL 编码与字段、TSV 解析（仅表头=0 命中）、reviewed 优先两档回退、http/network/timeout/aborted 归因、预中止不重试、体积截断（假 fetch，无网络）	24
`pp-nl-search.mjs`	首页内联候选端到端：中文描述→芯片「自然语言描述」→**候选就地出现在输入框下方**（不跳转）→行尾 ▶ 起**恰好 1 条** single 任务并渲染 3D 画布；勾 2 行→批量条起**恰好 1 条** batch 任务；全程断言 `localStorage` 任务行与 `api/archive` 条数不变（检索无痕）	—
`pp-lookup-fallback.mjs`	检索回退的诚实性：0 命中查询→面板依次显示「正在检索」→「正在理解你的描述并检索」→收敛为候选或诚实的「没有找到匹配的蛋白」，**不允许停在转圈**；两种结局均无痕	—
`pp-search-smoke.mjs` / `pp-archive-search.mjs`	检索页内联契约（候选在框下、不跳转、无痕、▶ 起 1 条任务）；遗留 `type=search` 归档仍能从 report.json 重建候选表	—
`pp-composer-inspect.mjs`	输入识别条：序列/ID/FASTA/描述四类芯片、FASTA 余项忽略、数字混入警告、批量 >8 截断提示、清空即清条	—

另有覆盖服务协议与数学口径的单元探针：`structure-service-unit.mts`、`confidence-multichain-unit.mts`、`pairwise-unit.mts`、`retry-unit.mts`、`pp-e2e-task.mts`、`pp-bff-probe.mts`。

运行示例：

```
npx tsx examples/packages/dev-tests/archive-put.mts        # 13 assertions passed
npx tsx examples/packages/dev-tests/boltz-flow-unit.mts    # 42 assertions passed
npx tsx examples/packages/dev-tests/pp-lddt-unit.mts       # lddt-unit probe: PASS (22 assertions)
npx tsc -b && npx biome check .                            # typecheck/lint 门禁
```

单元探针为本地执行（CI 门禁为 lint / typecheck / vitest，dev-tests 探针在本地跑）；最近一次本地全绿：2026-10-14 提交前复验（typecheck 通过、biome 0 错误、三项单元探针 77 断言全部通过）。

三、CASP14 基准实测分数（公网平台真实运行）

CASP14 靶标经公网平台首页真实提交（与普通用户操作完全一致：composer 输入序列 → agent 会话按链长自动选档 → 归档），由服务端 `api/bench` 以 RCSB 实验解析结构为真值独立打分。运行日期 2026-10-14，公网平台「基准」页（或 `GET /platform/api/bench`）可现场复核：

靶标	长度	参考结构（RCSB）	Cα-lDDT	Cα-RMSD
T1025	268 aa	6UV6	**0.952**	0.65 Å
T1030	273 aa	6POO	0.943	2.82 Å
T1046s2	142 aa	6PX4	0.859	1.71 Å

靶标	长度	参考结构（RCSB）	Cα-lDDT	Cα-RMSD
T1056	186 aa	6YJ1	0.817	3.36 Å

数据解读：四个靶标达到高精度（lDDT ≥ 0.8），最高精度 T1025 全残基 Cα-RMSD 0.65 Å。**置信度校准实测良好**：模型自报 pLDDT 与服务端实测 lDDT×100 高度一致——T1025 自报 94.6 vs 实测 95.2，T1046s2 自报 85.0 vs 实测 85.9。用户看 pLDDT 即可预判预测质量，平台的置信度体系真实可用而非装饰。分数谱与校准直方图见公网平台「基准」页（`api/bench` 直读），全部归档任务（含逐靶 report.json / model.pdb）保留在服务器，评审可任意抽查。

四、三类测试样例

正常样例

1. **单体 · `P69905`（血红蛋白 α，141 aa）**：ESMFold 预测成功，平均 pLDDT 94.7；`compare_with_alphafold` 与 AlphaFold DB 参考结构（AF-P69905-F1 v6）Horn 叠合后，核心区 Cα-RMSD **0.31 Å**（141 个双方 pLDDT≥70 的残基；全残基 0.34 Å），判定「与参考高度一致」。归档 taskId `tmv7ue2s0ujd8`，报告含逐残基 ΔpLDDT 序列可复核。
2. **复合物 · 双链 + 阿司匹林 SMILES**：Boltz-2 产出多链 PDB + PAE 热图，ipTM 评分与配体结合概率正常呈现。
3. **归档往返**：任务完成后换浏览器/设备打开「全部任务」，结果页完整重建（服务端归档，不依赖页面在线）。
4. **自然语言描述 · 「人类血红蛋白 α 链」**：UniProt 不索引中文，直查 0 命中 → 平台自动发起**一次隐藏 agent 回合**把中文翻成检索式，候选表**当场列在输入框下方**（无需跳转、无需去任务页）：行尾 ▶ 单选预测 P68871 并渲染 3D；勾选两行 + 批量条 → 一条 `batch_predict` 任务。检索这一步**不建任务、不写归档**（`pp-nl-search.mjs` 断言 `localStorage` 任务行与 `api/archive` 条数前后不变）。

边界样例

1. **长度边界 · 长链单体**：`predict_structure` 工具对 >1000 aa 直接拒绝；约 400 aa 以上送达公共 ESMFold 端点被拒（HTTP 413）时，失败信息明确指路 `predict_complex`，agent 会话随即按提示改走 Boltz-2 长链档（413 → 换档的完整链路记录在该任务的会话日志中，400+ aa 长链回退分支由 `boltz-flow-unit.mts` 的降级断言覆盖）。
2. **批量上限 · >8 个 UniProt ID**：输入框黄条提示「最多 8 个，仅取前 8 个」，服务端归档同样只处理前 8 个（`composer.ts` 的 `analyzeInput` 与 `archive.ts` 双侧一致）——截断显式可见，不静默丢弃。
3. **超长 PAE 矩阵 · >800 残基**：超过 1 MiB 结果预算时按块 mean-pool（`scale = ⌈n/800⌉`），热图仍可用且标注 scale（`protein-view/extensions/main/index.mjs` 的 `protein.pae` 分支）。
4. **归档超预算 · 大 PDB**：`pdb-*` 按体积从大到小丢弃、report.json 必存活（archive-put.mts「over budget」用例）。
5. **路径安全 · `../../etc/passwd`**：穿越路径解析为空，归档不含 report/pdb（archive-put.mts 路径穿越用例）。

异常样例

1. **鉴权失败回退 · 401**：托管 API bearer 失败自动换 `x-api-key` 头重试（boltz-flow-unit 断言）。
2. **任务失败呈现与恢复**：失败原因行明确展示 +「↻ 重新提交」原样重跑；运行中可两键取消，取消态与失败态严格区分。
3. **瞬时抖动**：网关超时/限流/连接中断自动重试最多两次（操作手册 §4 对用户公示的行为）。
4. **worker 缺席**：GPU worker 探活 1.5 s 失败 → 静默落回 API/本地档，任务照常完成（boltz-flow-unit 的死端口注入即模拟此场景）。
5. **描述完全无匹配**：输入「一种不存在的虚构蛋白质 泽塔奥米伽」→ 两档检索均 0 命中 → 面板给出「没有找到匹配的蛋白」并建议写法（蛋白名/基因名 + 物种，或直接给 ID/序列），**不会出现空表 + 转圈**；上游不可用与「没这个蛋白」在界面文案与 `api/uniprot` 返回的 `reason` 上严格区分（`pp-lookup-fallback.mjs`）。

每条样例均有对应自动化断言或可现场复现的公网操作，与《演示视频》分镜 6 对应。